

Celem tego badania jest zastosowanie technik Objaśnialnej Sztucznej Inteligencji (XAI) do analizy danych dotyczących grzybów. XAI pozwala na zrozumienie, jak modele sztucznej inteligencji, takie jak klasyfikatory, podejmują decyzje. Jest to szczególnie ważne w dziedzinach, w których dokładność i wiarygodność predykcji są kluczowe, jak w przypadku odróżniania grzybów jadalnych od trujących.

Za chwilę będziemy Państwa prosić o zinterpretowanie kilku wizualizacji (głównie wykresów), które pokazują, w jaki sposób sztuczna inteligencja (AI) przewiduje, że grzyb dziko rosnący, mający określone cechy, jest albo jadalny, albo niejadalny lub trujący.

Wyjściowy zbiór danych, na którym pracowała AI, pochodzi z UC Irvine Machine Learning Repository, czyli biblioteki ćwiczebnych zbiorów danych Uniwersytetu Kalifornijskiego w Irvine, przeznaczonych do trenowania (doskonalenia) algorytmów uczenia maszynowego.

Link do tego zbioru:










<https://archive.ics.uci.edu/dataset/848/secondary+mushroom+dataset>

Zbiór danych („dataset”) zawiera informacje o 61 069 owocnikach 173 gatunków grzybów sklasyfikowanych jako jadalne albo niejadalne lub trujące. Grzyby o nieznannej jadalności zostały zaliczone do niejadalnych lub trujących.

**Są to wyłącznie grzyby kapeluszowe mające trzon i hymenofor blaszkowy.**

Część danych to dane symulacyjne, hipotetyczne, czyli sztucznie wygenerowane na podstawie mniejszego zbioru rzeczywistych obserwacji grzybów występujących w przyrodzie.





Statystyki opisowe:

|              | średnica_kapelusza_cm | wysokość_trzonu_cm | szerokość_trzonu_mm |
|--------------|-----------------------|--------------------|---------------------|
| liczba       | 61069.00              | 61069.00           | 61069.00            |
| średnia      | 6.73                  | 6.58               | 12.15               |
| odch. stand. | 5.26                  | 3.37               | 10.04               |
| minimum      | 0.38                  | 0.00               | 0.00                |
| 25%          | 3.48                  | 4.64               | 5.21                |
| mediana      | 5.86                  | 5.95               | 10.19               |
| 75%          | 8.54                  | 7.74               | 16.57               |
| maksimum     | 62.34                 | 33.92              | 103.91              |

Brakujące dane (liczba i procent):

|                                                            | Kolumna                               | Liczba | Procent |
|------------------------------------------------------------|---------------------------------------|--------|---------|
|                                                            | typ_hymenoforu                        | 57892  | 94.80   |
|                                                            | kolor_zarodników                      | 54715  | 89.60   |
|                                                            | kolor_hymenoforu                      | 53656  | 87.86   |
|                                                            | podstawa_trzonu                       | 52597  | 86.13   |
|                                                            | powierzchnia_trzonu                   | 38124  | 62.43   |
|                                                            | gęstość_blaszek                       | 25063  | 41.04   |
|                                                            | powierzchnia_kapelusza                | 18552  | 30.38   |
|                                                            | sposób_przyrastania_blaszek_do_trzonu | 9884   | 16.18   |
|                                                            | typ_pierścienia                       | 2471   | 4.05    |
|                                                            | klasa                                 | 0      | 0.00    |
|                                                            | kolor_trzonu                          | 0      | 0.00    |
|                                                            | siedlisko                             | 0      | 0.00    |
|                                                            | obecność_pierścienia                  | 0      | 0.00    |
|                                                            | szerokość_trzonu_mm                   | 0      | 0.00    |
|                                                            | średnica_kapelusza_cm                 | 0      | 0.00    |
|                                                            | wysokość_trzonu_cm                    | 0      | 0.00    |
|                                                            | kolor_blaszek                         | 0      | 0.00    |
| zmienia_kolor_lub_puszcza_mleczko_w_reakcji_na_uszkodzenie |                                       | 0      | 0.00    |
|                                                            | kolor_kapelusza                       | 0      | 0.00    |
|                                                            | kształt_kapelusza                     | 0      | 0.00    |
|                                                            | pora_roku                             | 0      | 0.00    |

"Rój pszczół" – wpływ poszczególnych cech owocnika na predykcję jego jadalności (jadalny/niejadalny lub trujący)

**Legenda:**  
High = wysoka wartość cechy, np. „średnica\_kapelusza\_cm” (High) = duża średnica kapelusza w cm  
Low = niska wartość cechy, np. „wysokość\_trzonu\_cm” (Low) = krótki trzon  
„0” = granica między cechami, które mają duże i małe znaczenie w ocenie jadalności grzyba  
Dla cech binarnych (albo jest, albo jej nie ma) wartość wysoka (High), czyli kolor czerwony, oznacza: „cecha jest”.



Punkty po prawej (> 0.0) mają większy wpływ na klasyfikację grzyba przez model jako trującego, po lewej jako jadalnego

Wykres „wodospad”:  
wpływ cech danego  
owocnika na  
przewidywanie jego  
toksyczności

Legenda:

$E[f(X)]$ : wartość bazowa = średnia  
predykcja modelu dla wszystkich  
obserwacji

Szarfy kolorowe: wpływ danej  
cechy na predykcję toksyczności  
dla konkretnego owocnika


$f(x)$ : wartość ostateczna  
= predykcja modelu dla tego  
konkretnego owocnika

Analiza wpływu cech na przewidywanie dla klasy 'niejadalny/trujący' (dla grzyba, który faktycznie jest trujący)

Wkład poszczególnych cech w przewidywanie klasy grzyba przez model


Wartości pozytywne (w prawo) wskazują na wzrost prawdopodobieństwa  
klasyfikacji jako „niejadalnego/trującego” wg modelu, wartości negatywne (w lewo) – zmniejszenie

$E[f(x)]$  to średni wynik modelu, a  $f(X)$  to przewidywanie dla tej obserwacji





Wykres LIME: wartości cech grzybów zmniejszające lub zwiększające prawdopodobieństwo predykcji jadalny/niejadalny lub trujący



|                                       |                                     |                       |
|---------------------------------------|-------------------------------------|-----------------------|
| Porównanie z obserwacją numer #0:     |                                     |                       |
| Cecha                                 | Wartość oryginalna                  | Wartość zmodyfikowana |
| -----                                 |                                     |                       |
| średnica_kapelusza_cm                 | 9.41                                |                       |
| kształt_kapelusza                     | inne                                |                       |
| powierzchnia_kapelusza                | lepka                               |                       |
| kolor_kapelusza                       | żółty                               |                       |
| zmienia_kolor_lub_puszcza_            |                                     |                       |
| _mleczko_w_reakcji_na_uszkodzenie     | nie_zmienia_koloru_lub_brak_mleczka |                       |
| sposób_przyrastania_blaszek_do_trzonu | brak_danych                         |                       |
| gęstość_blaszek                       | gęste                               |                       |
| kolor_blaszek                         | pomarańczowy                        |                       |
| wysokość_trzonu_cm                    | 1.43                                | -> 23.5               |
| szerokość_trzonu_mm                   | 16.03                               |                       |
| podstawa_trzonu                       | brak_danych                         |                       |
| powierzchnia_trzonu                   | brak_danych                         |                       |
| kolor_trzonu                          | brązowy                             |                       |
| typ_hymenoforu                        | brak_danych                         |                       |
| kolor_hymenoforu                      | brak_danych                         |                       |
| kolor_zarodników                      | brak_danych                         |                       |
| siedlisko                             | lasy                                |                       |
| pora_roku                             | jesień                              |                       |

|                                       |                                     |                       |
|---------------------------------------|-------------------------------------|-----------------------|
| Porównanie z obserwacją numer #1:     |                                     |                       |
| Cecha                                 | Wartość oryginalna                  | Wartość zmodyfikowana |
| -----                                 |                                     |                       |
| średnica_kapelusza_cm                 | 9.41                                |                       |
| kształt_kapelusza                     | inne                                |                       |
| powierzchnia_kapelusza                | lepka                               |                       |
| kolor_kapelusza                       | żółty                               |                       |
| zmienia_kolor_lub_puszcza_            |                                     |                       |
| _mleczko_w_reakcji_na_uszkodzenie     | nie_zmienia_koloru_lub_brak_mleczka |                       |
| sposób_przyrastania_blaszek_do_trzonu | brak_danych                         |                       |
| gęstość_blaszek                       | gęste                               |                       |
| kolor_blaszek                         | pomarańczowy                        |                       |
| wysokość_trzonu_cm                    | 1.43                                | -> 23.2               |
| szerokość_trzonu_mm                   | 16.03                               |                       |
| podstawa_trzonu                       | brak_danych                         |                       |
| powierzchnia_trzonu                   | brak_danych                         |                       |
| kolor_trzonu                          | brązowy                             |                       |
| typ_hymenoforu                        | brak_danych                         |                       |
| kolor_hymenoforu                      | brak_danych                         |                       |
| kolor_zarodników                      | brak_danych                         |                       |
| siedlisko                             | lasy                                |                       |
| pora_roku                             | jesień                              |                       |

Analiza kontrfaktyczna:  
jak uzupełnienie przez AI brakujących danych  
w opisie konkretnego owocnika wpływa na zmianę  
predykcji jego jadalności

Objaśnienie:  
**Opisany na wizualizacji owocnik, badany realnie  
w przyrodzie, był NIEJADALNY/TRUJĄCY.**  
Model AI poprawnie przypisał go do przewidywanej  
klasy NIEJADALNY/TRUJĄCY.

Dwie przedstawione na obrazie analizy  
kontrfaktyczne mówią, jakie dane wystarczy  
zmienić, aby ten owocnik otrzymał predykcję  
**JADALNY.**

Legenda:  
Wartość pierwotna: dana pobrana dla konkretnego  
owocnika z pierwotnego zbioru danych

Wartość zmieniona: dana zmieniona lub  
uzupełniona przez model AI

W badaniu wykorzystano zaawansowany model uczenia maszynowego, znany jako **Klasyfikator wzmocnienia gradientowego** (w skrócie: "XGBClassifier"). Ten model osiągnął dokładność na poziomie **99,97%**, co świadczy o jego wysokiej skuteczności w odróżnianiu grzybów jadalnych od niejadalnych lub trujących.

**Wysoka dokładność:** Model skutecznie identyfikuje, czy dany grzyb jest jadalny czy niejadalny lub trujący, opierając się na analizie różnych cech owocnika.

**Bazowanie na danych:** Decyzje modelu opierają się wyłącznie na danych, które zostały mu dostarczone. Oznacza to, że model wykorzystuje dostępne informacje do wyciągania wniosków, ale *nie posiada wiedzy poza zakresem tych danych*.

**Ograniczenia modelu:** Chociaż model jest bardzo dokładny, należy pamiętać o jego ograniczeniach. Nie jest on w stanie uwzględnić wszystkich możliwych czynników wpływających na jadalność grzybów, które mogą być znane ekspertom. Model stanowi dodatkowe narzędzie wspomagające identyfikację grzybów. Jednakże, ze względu na ograniczenia modelu, zaleca się, aby nie traktować jego predykcji jako ostatecznego wyznacznika decyzji, a raczej jako jeden z elementów w procesie identyfikacji grzybów.

W naszym badaniu zastosowano standardową metodę podziału danych na dwie grupy: jedną do nauki modelu (zbiór treningowy) i drugą do jego testowania (zbiór testowy).

Example    Przykład

średnica\_kapelusza\_cm > 8.54  
kształt\_kapelusza = wypukły  
powierzchnia\_kapelusza = gładka  
kolor\_kapelusza = biały  
zmienia\_kolor\_lub\_puszcza\_mleczko\_w\_reakcji\_na\_uszkodzenie = nie\_zmienia\_koloru\_lub\_brak\_mleczka  
sposób\_przyrastania\_blaszek\_do\_trzonu = faliste  
gęstość\_blaszek = gęste  
kolor\_blaszek = biały  
5.96 < wysokość\_trzonu\_cm <= 7.74  
szerokość\_trzonu\_mm > 16.56  
podstawa\_trzonu = brak\_danych  
powierzchnia\_trzonu = brak\_danych  
kolor\_trzonu = biały  
typ\_hymenoforu = brak\_danych  
kolor\_hymenoforu = brak\_danych  
kolor\_zarodników = brak\_danych  
siedlisko = łąki  
pora\_roku = wiosna



A.I. prediction    Predykcja AI



"KOTWICA" (anchor)  
- metoda objaśniania modelu AI

Po prawej u góry: kotwica, czyli zestaw cech, których łączna obecność (koniunkcja) przesądza o sposobie zaklasyfikowania danego owocnika przez model AI.  
Kotwica nie musi odzwierciedlać rzeczywistego przykładu z danych.

Poniżej kotwicy: wpływ łącznego występowania zestawu cech (kotwicy) na procent przypadków, w których model przewiduje daną klasę (czyli tzw. pewność klasyfikacji).  
W wyliczaniu tego procentu model uwzględnia cechy zaznaczone na niebiesko.

Explanation of A.I. prediction    Objaśnienie kryteriów predykcji (decyzji) AI

If ALL of these are true:    Gdy wszystkie te cechy są spełnione

|                                     |                                                   |
|-------------------------------------|---------------------------------------------------|
| ✓ powierzchnia_trzonu = brak_danych | ✓ szerokość_trzonu_mm > 10.17                     |
| ✓ podstawa_trzonu = brak_danych     | ✓ powierzchnia_kapelusza = gładka                 |
| ✓ kolor_trzonu = biały              | ✓ sposób_przyrastania_blaszek_do_trzonu = faliste |
| ✓ średnica_kapelusza_cm > 5.87      | ✓ wysokość_trzonu_cm <= 7.74                      |

The A.I. will predict **jadalny** **97.2%** of the time  
AI przewiduje klasę JADALNY w 97,2% przypadków

If ALL of these are true:    Gdy wszystkie te cechy są spełnione


|                                     |                                                 |
|-------------------------------------|-------------------------------------------------|
| ✓ powierzchnia_trzonu = brak_danych | ✓ szerokość_trzonu_mm > 10.17                   |
| ✓ podstawa_trzonu = brak_danych     | ✓ powierzchnia_kapelusza = gładka               |
| ✓ kolor_trzonu = biały              | sposób_przyrastania_blaszek_do_trzonu = faliste |
| średnica_kapelusza_cm > 5.87        | wysokość_trzonu_cm <= 7.74                      |

The A.I. will predict **jadalny** **76.2%** of the time  
AI przewiduje klasę JADALNY w 76,2% przypadków

Example Przykład

5.87 < średnica\_kapelusza\_cm <= 8.54  
kształt\_kapelusza = płaski  
powierzchnia\_kapelusza = brak\_danych  
kolor\_kapelusza = zielony  
zmienia\_kolor\_lub\_puszcza\_mleczko\_w\_reakcji\_na\_uszkodzenie = nie\_zmienia\_koloru\_lub\_brak\_mleczka  
sposób\_przyrastania\_blaszek\_do\_trzonu = wykrojone  
gęstość\_blaszek = gęste  
kolor\_blaszek = brązowy  
5.96 < wysokość\_trzonu\_cm <= 7.74  
10.17 < szerokość\_trzonu\_mm <= 16.56  
podstawa\_trzonu = brak\_danych  
powierzchnia\_trzonu = brak\_danych  
kolor\_trzonu = biały  
typ\_hymenoforu = brak\_danych  
kolor\_hymenoforu = brak\_danych  
kolor\_zarodników = brak\_danych  
siedlisko = lasy  
pora\_roku = jesień

A.I. prediction Predykcja AI



trujący

## "KOTWICA" (anchor) - metoda objaśniania modelu AI

Po prawej u góry: kotwica, czyli zestaw cech, których łączna obecność (koniunkcja) przesądza o sposobie zaklasyfikowania danego owocnika przez model AI. Kotwica nie musi odzwierciedlać rzeczywistego przykładu z danych.

Poniżej kotwicy: wpływ łącznego występowania zestawu cech (kotwicy) na procent przypadków, w których model przewiduje daną klasę (czyli tzw. pewność klasyfikacji). W wyliczaniu tego procentu model uwzględnia cechy zaznaczone na niebiesko.

Explanation of A.I. prediction Objaśnienie kryteriów predykcji (decyzji) AI

If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ sposób\_przyrastania\_blaszek\_do\_trzonu = wykrojone
- ✓ kolor\_kapelusza = zielony
- ✓ powierzchnia\_kapelusza = brak\_danych
- ✓ kształt\_kapelusza = płaski
- ✓ średnica\_kapelusza\_cm > 5.87

The A.I. will predict **trujący** **97.5%** of the time  
AI przewiduje klasę TRUJĄCY w 97,5% przypadków


If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ sposób\_przyrastania\_blaszek\_do\_trzonu = wykrojone
- ✓ kolor\_kapelusza = zielony
- powierzchnia\_kapelusza = brak\_danych
- kształt\_kapelusza = płaski
- średnica\_kapelusza\_cm > 5.87


The A.I. will predict **trujący** **84.0%** of the time  
AI przewiduje klasę TRUJĄCY w 84,0% przypadków




Histogram dla średnica\_kapelusza\_cm




Wykres pudełkowy dla średnica\_kapelusza\_cm




Histogram dla wysokość\_trzonu\_cm



Wykres pudełkowy dla wysokość\_trzonu\_cm



Histogram dla szerokość\_trzonu\_mm



Wykres pudełkowy dla szerokość\_trzonu\_mm

