

W badaniu wykorzystano zaawansowany model uczenia maszynowego, znany jako **Klasyfikator wzmocnienia gradientowego** (w skrócie: "XGBClassifier"). Ten model osiągnął dokładność na poziomie **99,97%**, co świadczy o jego wysokiej skuteczności w odróżnianiu grzybów jadalnych od niejadalnych lub trujących.

Wysoka dokładność: Model skutecznie identyfikuje, czy dany grzyb jest jadalny czy niejadalny lub trujący, opierając się na analizie różnych cech owocnika.

Bazowanie na danych: Decyzje modelu opierają się wyłącznie na danych, które zostały mu dostarczone. Oznacza to, że model wykorzystuje dostępne informacje do wyciągania wniosków, ale *nie posiada wiedzy poza zakresem tych danych*.

Ograniczenia modelu: Chociaż model jest bardzo dokładny, należy pamiętać o jego ograniczeniach. Nie jest on w stanie uwzględnić wszystkich możliwych czynników wpływających na jadalność grzybów, które mogą być znane ekspertom. Model stanowi dodatkowe narzędzie wspomagające identyfikację grzybów. Jednakże, ze względu na ograniczenia modelu, zaleca się, aby nie traktować jego predykcji jako ostatecznego wyznacznika decyzji, a raczej jako jeden z elementów w procesie identyfikacji grzybów.

W naszym badaniu zastosowano standardową metodę podziału danych na dwie grupy: jedną do nauki modelu (zbiór treningowy) i drugą do jego testowania (zbiór testowy).

Celem tego badania jest zastosowanie technik Objaśnialnej Sztucznej Inteligencji (XAI) do analizy danych dotyczących grzybów. XAI pozwala na zrozumienie, jak modele sztucznej inteligencji, takie jak klasyfikatory, podejmują decyzje. Jest to szczególnie ważne w dziedzinach, w których dokładność i wiarygodność predykcji są kluczowe, jak w przypadku odróżniania grzybów jadalnych od trujących.


Za chwilę będziemy Państwa prosić o zinterpretowanie kilku wizualizacji (głównie wykresów), które pokazują, w jaki sposób sztuczna inteligencja (AI) przewiduje, że grzyb dziko rosnący, mający określone cechy, jest albo jadalny, albo niejadalny lub trujący.

Zbiór danych („dataset”) zawiera informacje o 61 069 owocnikach 173 gatunków grzybów sklasyfikowanych jako jadalne albo niejadalne lub trujące. Grzyby o nieznanej jadalności zostały zaliczone do niejadalnych lub trujących.

Są to wyłącznie grzyby kapeluszowe mające trzon i hymenofor blaszkowy.

Część danych to dane symulacyjne, hipotetyczne, czyli sztucznie wygenerowane na podstawie mniejszego zbioru rzeczywistych obserwacji grzybów występujących w przyrodzie.

Wykres LIME: wartości cech grzybów zmniejszające lub zwiększające prawdopodobieństwo predykcji jadalny/niejadalny lub trujący



Wykres „wodospad”:
wpływ cech danego
owocnika na
przewidywanie jego
toksyczności

Legenda:

$E[f(X)]$: wartość bazowa = średnia
predykcja modelu dla wszystkich
obserwacji

Szarfy kolorowe: wpływ danej
cechy na predykcję toksyczności
dla konkretnego owocnika


$f(x)$: wartość ostateczna
= predykcja modelu dla tego
konkretnego owocnika

Analiza wpływu cech na przewidywanie dla klasy 'niejadalny/trujący' (dla grzyba, który faktycznie jest trujący)










Wkład poszczególnych cech w przewidywanie klasy grzyba przez model

Wartości pozytywne (w prawo) wskazują na wzrost prawdopodobieństwa
klasyfikacji jako „niejadalnego/trującego” wg modelu, wartości negatywne (w lewo) – zmniejszenie

$E[f(x)]$ to średni wynik modelu, a $f(X)$ to przewidywanie dla tej obserwacji







Statystyki opisowe:

	średnica_kapelusza_cm	wysokość_trzonu_cm	szerokość_trzonu_mm
liczba	61069.00	61069.00	61069.00
średnia	6.73	6.58	12.15
odch. stand.	5.26	3.37	10.04
minimum	0.38	0.00	0.00
25%	3.48	4.64	5.21
mediana	5.86	5.95	10.19
75%	8.54	7.74	16.57
maksimum	62.34	33.92	103.91

Brakujące dane (liczba i procent):

	Kolumna	Liczba	Procent
	typ_hymenoforu	57892	94.80
	kolor_zarodników	54715	89.60
	kolor_hymenoforu	53656	87.86
	podstawa_trzonu	52597	86.13
	powierzchnia_trzonu	38124	62.43
	gęstość_blaszek	25063	41.04
	powierzchnia_kapelusza	18552	30.38
	sposób_przyrastania_blaszek_do_trzonu	9884	16.18
	typ_pierścienia	2471	4.05
	klasa	0	0.00
	kolor_trzonu	0	0.00
	siedlisko	0	0.00
	obecność_pierścienia	0	0.00
	szerokość_trzonu_mm	0	0.00
	średnica_kapelusza_cm	0	0.00
	wysokość_trzonu_cm	0	0.00
	kolor_blaszek	0	0.00
zmienia_kolor_lub_puszcza_mleczko_w_reakcji_na_uszkodzenie		0	0.00
	kolor_kapelusza	0	0.00
	kształt_kapelusza	0	0.00
	pora_roku	0	0.00

Porównanie z obserwacją numer #0:		
Cecha	Wartość oryginalna	Wartość zmodyfikowana

średnica_kapelusza_cm	9.41	
kształt_kapelusza	inne	
powierzchnia_kapelusza	lepka	
kolor_kapelusza	żółty	
zmienia_kolor_lub_puszcza_		
_mleczko_w_reakcji_na_uszkodzenie	nie_zmienia_koloru_lub_brak_mleczka	
sposób_przyrastania_blaszek_do_trzonu	brak_danych	
gęstość_blaszek	gęste	
kolor_blaszek	pomarańczowy	
wysokość_trzonu_cm	1.43	-> 23.5
szerokość_trzonu_mm	16.03	
podstawa_trzonu	brak_danych	
powierzchnia_trzonu	brak_danych	
kolor_trzonu	brązowy	
typ_hymenoforu	brak_danych	
kolor_hymenoforu	brak_danych	
kolor_zarodników	brak_danych	
siedlisko	lasy	
pora_roku	jesień	

Porównanie z obserwacją numer #1:		
Cecha	Wartość oryginalna	Wartość zmodyfikowana

średnica_kapelusza_cm	9.41	
kształt_kapelusza	inne	
powierzchnia_kapelusza	lepka	
kolor_kapelusza	żółty	
zmienia_kolor_lub_puszcza_		
_mleczko_w_reakcji_na_uszkodzenie	nie_zmienia_koloru_lub_brak_mleczka	
sposób_przyrastania_blaszek_do_trzonu	brak_danych	
gęstość_blaszek	gęste	
kolor_blaszek	pomarańczowy	
wysokość_trzonu_cm	1.43	-> 23.2
szerokość_trzonu_mm	16.03	
podstawa_trzonu	brak_danych	
powierzchnia_trzonu	brak_danych	
kolor_trzonu	brązowy	
typ_hymenoforu	brak_danych	
kolor_hymenoforu	brak_danych	
kolor_zarodników	brak_danych	
siedlisko	lasy	
pora_roku	jesień	

Analiza kontrfaktyczna:
jak uzupełnienie przez AI brakujących danych
w opisie konkretnego owocnika wpływa na zmianę
predykcji jego jadalności

Objaśnienie:
**Opisany na wizualizacji owocnik, badany realnie
w przyrodzie, był NIEJADALNY/TRUJĄCY.**
Model AI poprawnie przypisał go do przewidywanej
klasy NIEJADALNY/TRUJĄCY.

Dwie przedstawione na obrazie analizy
kontrfaktyczne mówią, jakie dane wystarczy
zmienić, aby ten owocnik otrzymał predykcję
JADALNY.

Legenda:
Wartość pierwotna: dana pobrana dla konkretnego
owocnika z pierwotnego zbioru danych

Wartość zmieniona: dana zmieniona lub
uzupełniona przez model AI

Example Przykład

średnica_kapelusza_cm > 8.54
kształt_kapelusza = wypukły
powierzchnia_kapelusza = gładka
kolor_kapelusza = biały
zmienia_kolor_lub_puszcza_mleczko_w_reakcji_na_uszkodzenie = nie_zmienia_koloru_lub_brak_mleczka
sposób_przyrastania_blaszek_do_trzonu = faliste
gęstość_blaszek = gęste
kolor_blaszek = biały
5.96 < wysokość_trzonu_cm <= 7.74
szerokość_trzonu_mm > 16.56
podstawa_trzonu = brak_danych
powierzchnia_trzonu = brak_danych
kolor_trzonu = biały
typ_hymenoforu = brak_danych
kolor_hymenoforu = brak_danych
kolor_zarodników = brak_danych
siedlisko = łąki
pora_roku = wiosna



A.I. prediction Predykcja AI



"KOTWICA" (anchor)
- metoda objaśniania modelu AI

Po prawej u góry: kotwica, czyli zestaw cech, których łączna obecność (koniunkcja) przesądza o sposobie zaklasyfikowania danego owocnika przez model AI.
Kotwica nie musi odzwierciedlać rzeczywistego przykładu z danych.

Poniżej kotwicy: wpływ łącznego występowania zestawu cech (kotwicy) na procent przypadków, w których model przewiduje daną klasę (czyli tzw. pewność klasyfikacji).
W wyliczaniu tego procentu model uwzględnia cechy zaznaczone na niebiesko.

Explanation of A.I. prediction Objaśnienie kryteriów predykcji (decyzji) AI

If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ powierzchnia_trzonu = brak_danych ✓ szerokość_trzonu_mm > 10.17
- ✓ podstawa_trzonu = brak_danych ✓ powierzchnia_kapelusza = gładka
- ✓ kolor_trzonu = biały ✓ sposób_przyrastania_blaszek_do_trzonu = faliste
- ✓ średnica_kapelusza_cm > 5.87 ✓ wysokość_trzonu_cm <= 7.74

The A.I. will predict **jadalny** **97.2%** of the time
AI przewiduje klasę JADALNY w 97,2% przypadków

If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ powierzchnia_trzonu = brak_danych ✓ szerokość_trzonu_mm > 10.17
- ✓ podstawa_trzonu = brak_danych ✓ powierzchnia_kapelusza = gładka
- ✓ kolor_trzonu = biały sposób_przyrastania_blaszek_do_trzonu = faliste
- średnica_kapelusza_cm > 5.87 wysokość_trzonu_cm <= 7.74


The A.I. will predict **jadalny** **76.2%** of the time
AI przewiduje klasę JADALNY w 76,2% przypadków

Example Przykład

5.87 < średnica_kapelusza_cm <= 8.54
kształt_kapelusza = płaski
powierzchnia_kapelusza = brak_danych
kolor_kapelusza = zielony
zmienia_kolor_lub_puszcza_mleczko_w_reakcji_na_uszkodzenie = nie_zmienia_koloru_lub_brak_mleczka
sposób_przyrastania_blaszek_do_trzonu = wykrojone
gęstość_blaszek = gęste
kolor_blaszek = brązowy
5.96 < wysokość_trzonu_cm <= 7.74
10.17 < szerokość_trzonu_mm <= 16.56
podstawa_trzonu = brak_danych
powierzchnia_trzonu = brak_danych
kolor_trzonu = biały
typ_hymenoforu = brak_danych
kolor_hymenoforu = brak_danych
kolor_zarodników = brak_danych
siedlisko = lasy
pora_roku = jesień



A.I. prediction Predykcja AI



trujący

"KOTWICA" (anchor) - metoda objaśniania modelu AI

Po prawej u góry: kotwica, czyli zestaw cech, których łączna obecność (koniunkcja) przesądza o sposobie zaklasyfikowania danego owocnika przez model AI. Kotwica nie musi odzwierciedlać rzeczywistego przykładu z danych.

Poniżej kotwicy: wpływ łącznego występowania zestawu cech (kotwicy) na procent przypadków, w których model przewiduje daną klasę (czyli tzw. pewność klasyfikacji). W wyliczaniu tego procentu model uwzględnia cechy zaznaczone na niebiesko.

Explanation of A.I. prediction Objaśnienie kryteriów predykcji (decyzji) AI

If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ sposób_przyrastania_blaszek_do_trzonu = wykrojone
- ✓ kolor_kapelusza = zielony
- ✓ powierzchnia_kapelusza = brak_danych
- ✓ kształt_kapelusza = płaski
- ✓ średnica_kapelusza_cm > 5.87

The A.I. will predict **trujący** **97.5%** of the time
AI przewiduje klasę TRUJĄCY w 97,5% przypadków

If ALL of these are true: Gdy wszystkie te cechy są spełnione

- ✓ sposób_przyrastania_blaszek_do_trzonu = wykrojone
- ✓ kolor_kapelusza = zielony
- powierzchnia_kapelusza = brak_danych
- kształt_kapelusza = płaski
- średnica_kapelusza_cm > 5.87


The A.I. will predict **trujący** **84.0%** of the time
AI przewiduje klasę TRUJĄCY w 84,0% przypadków

Wyjściowy zbiór danych, na którym pracowała AI, pochodzi z UC Irvine Machine Learning Repository, czyli biblioteki ćwiczebnych zbiorów danych Uniwersytetu Kalifornijskiego w Irvine, przeznaczonych do trenowania (doskonalenia) algorytmów uczenia maszynowego.


Link do tego zbioru:

<https://archive.ics.uci.edu/dataset/848/secondary+mushroom+dataset>


Histogram dla średnica_kapelusza_cm




Wykres pudełkowy dla średnica_kapelusza_cm




Histogram dla wysokość_trzonu_cm




Wykres pudełkowy dla wysokość_trzonu_cm



Histogram dla szerokość_trzonu_mm



Wykres pudełkowy dla szerokość_trzonu_mm



"Rój pszczół" – wpływ poszczególnych cech owocnika na predykcję jego jadalności (jadalny/niejadalny lub trujący)

